



הנגשת זכויות חברתיות באמצעות NLP

אחזור סמנטי בעברית לשאלות על זכויות חברתיות

האם חיפוש מבוסס-משמעות מנצח חיפוש מבוסס-מילים בשאלות יומיומיות של אזרחים – והאם שילוב השניים מנצח את שניהם?


הפער בין איך שואלים לבין איך הזכויות מנוסחות

אזרחים מתארים את מצבם בשפה יומיומית ורגשית. המקורות הרשמיים עונים בעברית פורמלית-משפטית. חיפוש מבוסס-מילים נופל בדיוק בפער שביניהם.



איך אנשים שואלים

“פיטרו אותי מהעבודה, מה מגיע לי”
 “התינוק שלי מתעכב בהתפתחות, לאן פונים”
 “יש לי אוטו, זה פוסל אותי מקצבה”



איך המקורות מנוסחים

“זכאות לדמי אבטלה”
 “אבחון רפואי התפתחותי לילדים”
 “זכאות לגמלת הבטחת הכנסה ובעלות על רכב”

אותה משמעות • לעיתים קרובות ללא מילים משותפות

האם אחזור מבוסס-משמעות עוזר — והאם שילובו עם חיפוש מילים עוזר יותר?

H2

היברידי < שניהם

שילוב דירוגים לקסיקלי + סמנטי מנצח כל שיטה בודדת באיכות הדירוג (MRR, nDCG).


H1

סמנטי < לקסיקלי

ההטמעות של AlephBERT מנצחות את TF-IDF, במיוחד כששאלה מנוסחת רחוק מנוסח המקור.

ספויילר: השערה אחת מתאשרת, אחת נדחית — והניגוד הזה הוא הממצא.

צינור העיבוד מקצה לקצה



הרצה בפקודה אחת: `python src/run_all.py`

קורפוס עברי של זכויות שנאסף עצמאית

6

תחומי חיים

122,928

טוקנים

1,602

פסקאות

296

מסמכים



כל-זכות · מקור עיקרי

- שמחזיר טקסט נקי ומובנה MediaWiki רשמי של API
- שש קטגוריות: נכות, אבטלה, בריאות, ילדים, הבטחת הכנסה, הורות
- (שימוש חוזר עם ייחוס) CC-BY-SA: רישיון



ביטוח לאומי · מקור משלים

- בלבד #mainContent, דפי זכאות נבחרים
- מזהה User-Agent · קצב מוגבל · robots.txt נבדק
- מוסיף את המשלב הפורמלי המנוגד לכל-זכות

סט הערכה: 40 שאלות יומיומיות שחוברו ידנית, ממופות למסמכי אמת ומתויגות לפי פער-הניסוח.

מטקסט עברי גולמי לטוקנים נקיים

כל פסקה עוברת שרשרת עיבוד מקדים קלאסית לפני האינדוקס הלקסיקלי.

גולמי

...שכירים שפוטרו או התפטרו, כולל מי שעבדו בשני מקומות עבודה...

נרמול

הסרת ניקוד • הסרת פיסוק ולטינית • אותיות קטנות • צמצום רווחים

טוקניזציה

שכירים • שפוטרו • או • התפטרו • כולל • מי • שעבדו • בשני • מקומות • עבודה

הסרת מילות עצירה

הוסרו: או • מי • וכן • כדי • על • עד • נותרו 26 מתוך 33 טוקנים

זרם הטוקנים הנקי מוזן למודלים הלקסיקליים TF-IDF ו-BM25

וקטוריזציה של הקורפוס עם TF-IDF

מטריצת מסמך-מונח

צורה $1,602 \times 20,981$

אוצר מילים מונחים 20,981

יוניגרמים / ביגרמים 7,323 / 13,658

ערכים שאינם אפס 141,493

דלילות 99.58%



פסקה אחת כוקטור דליל

פסקה: "דמי אבטלה" – המונחים בעלי המשקל הגבוה ביותר

0.175 לחל ת

0.160 לעבוד

0.157 בקצרה שכירים

0.157 בתנאים מסוימים

0.157 זכאי דמי

0.157 לשכירים

כל פסקה = נקודה במרחב בן 20,981 ממדים; הדירוג = דמיון קוסינוס לוקטור השאילתה.

המורפולוגיה העברית מנפחת את אוצר המילים

העברית מדביקה מיליות (ב.ל.מ.ה.ו.ש.כ) לתחילת המילים, כך שאותו שורש מופיע בצורות רבות – אתגר אמיתי לחיפוש מבוסס-מילים.



הסרת תחיליות קלה (הדגמת stemming)

עובדים	›	לעובדים
המעסיק	›	והמעסיק
עובד	›	כשעובד
תקופת	›	בתקופת
מוסד	›	מהמוסד

ההשפעה על אוצר המילים

13,415 < 8,963

סוגי מילים, לאחר הסרת תחילית אחת

–33%

המורפולוגיה – לא הנושא – אחראית לרוב הדלילות. למטיזציה מלאה היא עבודה עתידית.

חמישה מאחזרים, ממשק אחד



AlephBERT

סמנטי

הטמעות משפט בעברית, קוסינוס צפוף



BM25

לקסיקלי (בונוס)

דירוג Okapi BM25



TF-IDF

בסיס לקסיקלי

קוסינוס דליל מעל מטריצת המונחים



Hybrid-wtd

שילוב

שילוב ציוני α min-max: α סמנטי + $(\alpha-1)$ לקסיקלי



Hybrid-RRF

שילוב

שילוב דירוגים הופכיים של לקסיקלי + סמנטי


שילוב היברידי והמדדים



Reciprocal Rank Fusion

$$\text{score}(d) = \sum 1 / (k + \text{rank}_i(d))$$

- מבוסס-דירוג — לא נדרש כיול ציונים
- מסמך שדורג גבוה ע"י אחד המודלים עולה
- (min-max) נבדק גם שילוב ציונים משוקלל



מדדי הערכה

Recall@k

האם מסמך רלוונטי נמצא ב-top-k?

MRR

1 חלקי דירוג המסמך הרלוונטי הראשון

nDCG@10

מתגמל מסמכים רלוונטיים בדירוג גבוה

MAP

דיוק ממוצע על פני כל הדירוג

המדדה היא ברמת המסמך: פסקה נחשבת עבור הדף שאליו היא שייכת.

חלוקה לאימון · ולידציה · טסט

זהו אחזור מידע, ולכן החלוקה היא ברמת השאילתה: הקורפוס משמש כאינדקס (נלמד ללא תוויות), ו-40 השאלות המתויגות מחולקות לולידציה ולטסט.



טסט (מוחזק)

26 שאלות · 65%

מדדים סופיים ובלתי-מוטים — לא השפיעו על אף בחירה



ולידציה (dev)

14 שאלות · 35%

בחירת מודל והיפר-פרמטרים (שיטת השילוב, (k, α))



קורפוס · אינדקס

296 מסמכים · 1,602 פסקאות


ללא תוויות — TF-IDF/BM25 נלמדים עליו ו-AlephBERT מקודד אותו

MRR: על הטסט המוחזק (26 שאלות) — Hybrid-RRF 0.690 · Hybrid-wtd 0.659 · BM25 0.606 · TF-IDF 0.603 · AlephBERT 0.585

היתרון של ההיברידי נשמר — ואף גדל — על שאלות שלא השתתפו בשום בחירה.

השוואת חמשת המודלים

דירוג הדדי ממוצע (MRR)



MAP	nDCG	MRR	R@10	R@5	R@1	
0.588	0.649	0.618	0.850	0.825	0.475	TF-IDF
0.578	0.647	0.612	0.875	0.825	0.500	BM25
0.540	0.597	0.579	0.775	0.725	0.475	AlephBERT
0.652	0.704	0.668	0.875	0.800	0.550	Hybrid-RRF
0.632	0.681	0.653	0.850	0.800	0.550	Hybrid-wtd

שורה מודגשת = הטוב ביותר. Hybrid-RRF מוביל בכל מדדי הדירוג.

הסמנטי לבדו הפסיד. ההיברידי ניצח.



מדוע

שני המודלים נכשלים אחרת. הסמנטי מציל פראפרזות ללא מילים משותפות שהלקסיקלי לא; משולבים, נשמר הדיוק ונוסף כיסוי — משלימים, לא עדיפים.



H2 אושרה

Hybrid-RRF מוביל בכול: nDCG 0.704, MRR 0.668, והכי מעט החטאות (5/40). השילוב הוא המנצח המעשי.



H1 נדחתה

AlephBERT לבדו הוא המודל החלש ביותר — MRR 0.579, 9 מתוך 40 החטאות — ואינו מנצח את הלקסיקלי אפילו בשאלות עם פער-ניסוח גבוה (R@1 0.44 מול 0.48).

Recall@k ומבחן פער-הניסוח


Recall@1 לפי פער-הניסוח (מבחן H1)

היברדי	AlephBERT	TF-IDF	n	פער
0.75	0.50	0.25	4	נמוך
0.64	0.55	0.55	11	בינוני
0.48	0.44	0.48	25	גבוה




אפילו בשאלות הקשות והמנוסחות-מחדש ביותר, הסמנטי אינו מקדים (0.44 מול 0.48). היתרון הסמנטי הצפוי פשוט אינו קיים במודל מדף זה.

Recall@k כתלות ב-k



היכן כל מודל מנצח, שאלה אחר שאלה



כיצד לקרוא את מפת החום

- כל שורה היא אחת מ-40 השאלות; הצבע = דירוג המסמך הנכון הראשון (ירוק = למעלה, אדום = עמוק, אפור = הוחמץ).
- ירוקים ואפורים מתחלפים בין העמודות – המודלים מצליחים ונכשלים בשאלות שונות.
 - אי-ההסכמה הזו היא בדיוק מה שהופך את השילוב למשתלם

היברידי 5 • AlephBERT 9 • TF-IDF 6 (top-10 מסמך האמת לא ב) החטאות

שלוש תבניות, דוגמאות אמיתיות



A · הסמנטי מנצח

4 מקרים

“חייבים להגיע ללשכת התעסוקה כל הזמן?”

אמת: התייצבות בשירות התעסוקה. אפס מילים משותפות → לקסיקלי דירוג 4, סמנטי דירוג 1.



B · הלקסיקלי מנצח

5 מקרים

“כיסא גלגלים ומכשירי שיקום?”

אמת: אביזרי ומכשירי שיקום. מונח מדויק אחד → לקסיקלי דירוג 1, סמנטי מחמיץ.



C · שניהם נכשלים


7 מקרים

“איך מקבלים קצבת נכות?”

הדף הקרוב ביותר הוא קצרמר של ביטוח לאומי, מוצף בדפי “קביעת נכות” ספציפיים.

כך נראה מרחב ההטמעות

t-SNE of AlephBERT passage embeddings, colored by domain



t-SNE של וקטורי הפסקאות

- מוטלות ל-2 ממדים, צבועות לפי AlephBERT הטמעות תחום חיים.
- התחומים יוצרים אשכולות – המודל אכן לוכד משמעות נושאית
- אך האשכולות חופפים, ולכן דירוג עדין עדיין זקוק לאות הלקסיקלי

מה הפרויקט מראה



צינור IR עברי מלא

קורפוס שנאסף עצמאית → עיבוד מקדים → 5 מאחזרים → הערכה קפדנית, ניתן לשחזור מלא.



ההיברידי הוא ההמלצה

המודל היחיד שמנצח את שני קווי הבסיס בכל מדדי הדירוג.



מדף ≠ ניצחון חינם

מקודד עברי מבוסס masked-LM הוא משלים שימושי, לא שדרוג מיידי לאחזור.



המשך

מודל מכוון-אחזור (E5), למטיזציה עברית, וסט הערכה גדול ומדורג יותר.

אתיקה ומגבלות



נתונים ציבוריים ומורשים

כל-זכות (CC-BY-SA) + מידע ציבורי של ביטוח לאומי. ללא מידע אישי, ללא סריקת תוכן משתמשים.



אינו ייעוץ משפטי

אב-טיפוס מחקרי. שימוש אמיתי חייב להציג קישורי מקור ולהפנות לרשות המוסמכת.



הטיה וכיסוי

שישה תחומים בלבד; המורפולוגיה העברית פוגעת בלקסיקלי; ל-AlephBERT ייתכנו הטיות מקדם-אימון.



סט הערכה קטן

40 שאלות, מתייג יחיד: מצביע על מגמה, אך אינו מובהק סטטיסטית.



תודה

אחזור סמנטי בעברית לשאלות על זכויות חברתיות

יניק גוטיה · github.com/YanikGotie/hebrew-rights-retrieval



גילוי נאות על שימוש ב-AI

נעשה שימוש בעוזר AI ככלי לכתיבת קוד (תבניות, תיעוד, ניפוי שגיאות). תכנון המחקר, הנתונים, סט ההערכה והמסקנות הם של המחבר; כל הקוד נבדק והובן.