



# הנגשת זכויות חברתיות באמצעות NLP

*אחזור סמנטי בעברית לשאלות על זכויות חברתיות*

האם חיפוש מבוסס-משמעות מנצח חיפוש מבוסס-מילים בשאלות יומיומיות של אזרחים – והאם שילוב השניים מנצח את שניהם?


# הפער בין איך שואלים לבין איך הזכויות מנוסחות

אזרחים מתארים את מצבם בשפה יומיומית ורגשית. המקורות הרשמיים עונים בעברית פורמלית-משפטית. חיפוש מבוסס-מילים נופל בדיוק בפער שביניהם.



## איך אנשים שואלים

“פיטרו אותי מהעבודה, מה מגיע לי”  
 “התינוק שלי מתעכב בהתפתחות, לאן פונים”  
 “יש לי אוטו, זה פוסל אותי מקצבה”



## איך המקורות מנוסחים

“זכאות לדמי אבטלה”  
 “אבחון רפואי התפתחותי לילדים”  
 “זכאות לגמלת הבטחת הכנסה ובעלות על רכב”

אותה משמעות • לעיתים קרובות ללא מילים משותפות

# האם אחזור מבוסס-משמעות עוזר — והאם שילובו עם חיפוש מילים עוזר יותר?

H2

היברידי < שניהם

שילוב דירוגים לקסיקלי + סמנטי מנצח כל שיטה בודדת באיכות הדירוג (MRR, nDCG).


H1

סמנטי < לקסיקלי

ההטמעות של AlephBERT מנצחות את TF-IDF, במיוחד כששאלה מנוסחת רחוק מנוסח המקור.

ספויילר: השערה אחת מתאשרת, אחת נדחית — והניגוד הזה הוא הממצא.

# צינור העיבוד מקצה לקצה



הרצה בפקודה אחת: `python src/run_all.py`

# קורפוס עברי של זכויות שנאסף עצמאית

6

תחומי חיים

122,928

טוקנים

1,602

פסקאות

296

מסמכים



## כל-זכות · מקור עיקרי

- שמחזיר טקסט נקי ומובנה MediaWiki רשמי של API
- שש קטגוריות: נכות, אבטלה, בריאות, ילדים, הבטחת הכנסה, הורות
- (שימוש חוזר עם ייחוס) CC-BY-SA: רישיון



## ביטוח לאומי · מקור משלים

- בלבד #mainContent, דפי זכאות נבחרים
- מזהה User-Agent · קצב מוגבל · robots.txt נבדק
- מוסיף את המשלב הפורמלי המנוגד לכל-זכות

סט הערכה: 40 שאלות יומיומיות שחוברו ידנית, ממופות למסמכי אמת ומתויגות לפי פער-הניסוח.

# מטקסט עברי גולמי לטוקנים נקיים

כל פסקה עוברת שרשרת עיבוד מקדים קלאסית לפני האינדוקס הלקסיקלי.

גולמי

...שכירים שפוטרו או התפטרו, כולל מי שעבדו בשני מקומות עבודה...

נרמול

הסרת ניקוד • הסרת פיסוק ולטינית • אותיות קטנות • צמצום רווחים

טוקניזציה

שכירים • שפוטרו • או • התפטרו • כולל • מי • שעבדו • בשני • מקומות • עבודה

הסרת מילות עצירה

הוסרו: או • מי • וכן • כדי • על • עד • נותרו 26 מתוך 33 טוקנים

# וקטוריזציה של הקורפוס עם TF-IDF

## מטריצת מסמך-מונח

צורה  $1,602 \times 20,981$

אוצר מילים מונחים 20,981

יוניגרמים / ביגרמים 7,323 / 13,658

ערכים שאינם אפס 141,493

דלילות 99.58%



## פסקה אחת כוקטור דליל

פסקה: "דמי אבטלה" – המונחים בעלי המשקל הגבוה ביותר

0.175 לחל ת

0.160 לעבוד

0.157 בקצרה שכירים

0.157 בתנאים מסוימים

0.157 זכאי דמי

0.157 לשכירים

כל פסקה = נקודה במרחב בן 20,981 ממדים; הדירוג = דמיון קוסינוס לוקטור השאילתה.

# המורפולוגיה העברית מנפחת את אוצר המילים

העברית מדביקה מיליות (ב.ל.מ.ה.ו.ש.כ) לתחילת המילים, כך שאותו שורש מופיע בצורות רבות – אתגר אמיתי לחיפוש מבוסס-מילים.



## הסרת תחיליות קלה (הדגמת stemming)

|        |   |         |
|--------|---|---------|
| עובדים | › | לעובדים |
| המעסיק | › | והמעסיק |
| עובד   | › | כשעובד  |
| תקופת  | › | בתקופת  |
| מוסד   | › | מהמוסד  |

## ההשפעה על אוצר המילים

13,415 < 8,963

סוגי מילים, לאחר הסרת תחילית אחת

–33%

המורפולוגיה – לא הנושא – אחראית לרוב הדלילות. למטיזציה מלאה היא עבודה עתידית.



# חמישה מאחזרים, ממשק אחד



**AlephBERT**

סמנטי

הטמעות משפט בעברית, קוסינוס צפוף



**BM25**

לקסיקלי (בונוס)

דירוג Okapi BM25



**TF-IDF**

בסיס לקסיקלי

קוסינוס דליל מעל מטריצת המונחים



**Hybrid-wtd**

שילוב

שילוב ציוני  $\alpha$  min-max:  $\alpha$  סמנטי +  $(\alpha-1)$  לקסיקלי



**Hybrid-RRF**

שילוב

שילוב דירוגים הופכיים של לקסיקלי + סמנטי

# שאלתה אחת, שלושה מודלים

“השאלתה: פטרו אותי מהעבודה, מה מגיע לי

מסמך הזהב: דמי אבטלה” · זכאות לדמי אבטלה



## לקסיקלי · TF-IDF

1. זכאות לגמלת הבטחת הכנסה ובעלות על רכב
2. ניכוי הכנסות מדמי אבטלה
3. איסור ניכוי שכר מנער הנעדר מעבודתו...

❓ מסמך הזהב לא הופיע ב-top-10



## סמנטי · AlephBERT

1. דמי אבטלה
2. דמי אבטלה בתקופת מלחמת חרבות ברזל
3. התפטרות בנסיבות המזכות בדמי אבטלה

✓ מסמך הזהב במקום 1

4: Hybrid-RRF · 1: AlephBERT · X: TF-IDF — דירוג מסמך הזהב

אפס מילים משותפות → הלקסיקלי מחמיץ, הסמנטי מגשר על פער הניסוח. ההיברידי אינו ראשון בכל שאלה — יתרונו הוא במצטבר על פני 40 השאלות.


# שילוב היברידי והמדדים



## Reciprocal Rank Fusion

$$\text{score}(d) = \sum 1 / (k + \text{rank}_i(d))$$

- מבוסס-דירוג — לא נדרש כיוול ציונים
- מסמך שדורג גבוה ע"י אחד המודלים עולה
- (min-max) נבדק גם שילוב ציונים משוקלל



## מדדי הערכה

**Recall@k**

האם מסמך רלוונטי נמצא ב-top-k?

**MRR**

1 חלקי דירוג המסמך הרלוונטי הראשון

**nDCG@10**

מתגמל מסמכים רלוונטיים בדירוג גבוה

**MAP**

דיוק ממוצע על פני כל הדירוג

המדדה היא ברמת המסמך: פסקה נחשבת עבור הדף שאליו היא שייכת.

# חלוקה לאימון • ולידציה • טסט

זהו אחזור מידע, ולכן החלוקה היא ברמת השאילתה: הקורפוס משמש כאינדקס (נלמד ללא תוויות), ו-40 השאלות המתויגות מחולקות לולידציה ולטסט.



## טסט (מוחזק)

26 שאלות • 65%

מדדים סופיים ובלתי-מוטים — לא השפיעו על אף בחירה



## ולידציה (dev)

14 שאלות • 35%

בחירת מודל והיפר-פרמטרים (שיטת השילוב,  $(k, \alpha)$ )



## קורפוס • אינדקס

296 מסמכים • 1,602 פסקאות


ללא תוויות — TF-IDF/BM25 נלמדים עליו ו-AlephBERT מקודד אותו

MRR: על הטסט המוחזק (26 שאלות) — Hybrid-RRF 0.690 • Hybrid-wtd 0.659 • BM25 0.606 • TF-IDF 0.603 • AlephBERT 0.585

היתרון של ההיברידי נשמר — ואף גדל — על שאלות שלא השתתפו בשום בחירה.

# השוואת חמשת המודלים

דירוג הדדי ממוצע (MRR)



| MAP   | nDCG  | MRR   | R@10  | R@5   | R@1   |            |
|-------|-------|-------|-------|-------|-------|------------|
| 0.588 | 0.649 | 0.618 | 0.850 | 0.825 | 0.475 | TF-IDF     |
| 0.578 | 0.647 | 0.612 | 0.875 | 0.825 | 0.500 | BM25       |
| 0.540 | 0.597 | 0.579 | 0.775 | 0.725 | 0.475 | AlephBERT  |
| 0.652 | 0.704 | 0.668 | 0.875 | 0.800 | 0.550 | Hybrid-RRF |
| 0.632 | 0.681 | 0.653 | 0.850 | 0.800 | 0.550 | Hybrid-wtd |

שורה מודגשת = הטוב ביותר. Hybrid-RRF מוביל בכל מדדי הדירוג.

# הסמנטי לבדו הפסיד. ההיברידי ניצח.



## מדוע

שני המודלים נכשלים אחרת. הסמנטי מציל פראפרזות ללא מילים משותפות שהלקסיקלי לא; משולבים, נשמר הדיוק ונוסף כיסוי — משלימים, לא עדיפים.



## H2 אושרה

Hybrid-RRF מוביל בכול: nDCG 0.704, MRR 0.668, והכי מעט החטאות (5/40). השילוב הוא המנצח המעשי.



## H1 נדחתה

AlephBERT לבדו הוא המודל החלש ביותר — MRR 0.579, 9 מתוך 40 החטאות — ואינו מנצח את הלקסיקלי אפילו בשאלות עם פער-ניסוח גבוה (R@1 0.44 מול 0.48).

# Recall@k ומבחן פער-הניסוח


Recall@1 לפי פער-הניסוח (מבחן H1)

| היברידי | AlephBERT | TF-IDF | n  | פער    |
|---------|-----------|--------|----|--------|
| 0.75    | 0.50      | 0.25   | 4  | נמוך   |
| 0.64    | 0.55      | 0.55   | 11 | בינוני |
| 0.48    | 0.44      | 0.48   | 25 | גבוה   |




אפילו בשאלות הקשות והמנוסחות-מחדש ביותר, הסמנטי אינו מקדים (0.44 מול 0.48). היתרון הסמנטי הצפוי פשוט אינו קיים במודל מדף זה.

Recall@k כתלות ב-k



# היכן כל מודל מנצח, שאלה אחר שאלה



## כיצד לקרוא את מפת החום

- כל שורה היא אחת מ-40 השאלות; הצבע = דירוג המסמך הנכון הראשון (ירוק = למעלה, אדום = עמוק, אפור = הוחמץ).
- ירוקים ואפורים מתחלפים בין העמודות – המודלים מצליחים ונכשלים בשאלות שונות.
  - אי-ההסכמה הזו היא בדיוק מה שהופך את השילוב למשתלם

היברידי 5 • AlephBERT 9 • TF-IDF 6 (top-10 מסמך האמת לא ב) החטאות



# שלוש תבניות, דוגמאות אמיתיות



## A · הסמנטי מנצח

4 מקרים

“חייבים להגיע ללשכת התעסוקה כל הזמן?”

אמת: התייצבות בשירות התעסוקה. אפס מילים משותפות → לקסיקלי דירוג 4, סמנטי דירוג 1.



## B · הלכסיקלי מנצח

5 מקרים

“כיסא גלגלים ומכשירי שיקום?”

אמת: אביזרי ומכשירי שיקום. מונח מדויק אחד → לקסיקלי דירוג 1, סמנטי מחמיץ.



## C · שניהם נכשלים


7 מקרים

“איך מקבלים קצבת נכות?”

הדף הקרוב ביותר הוא קצרמר של ביטוח לאומי, מוצף בדפי “קביעת נכות” ספציפיים.

# כך נראה מרחב ההטמעות

t-SNE of AlephBERT passage embeddings, colored by domain



## t-SNE של וקטורי הפסקאות

- מוטלות ל-2 ממדים, צבועות לפי AlephBERT הטמעות תחום חיים.
- התחומים יוצרים אשכולות – המודל אכן לוכד משמעות נושאית
- אך האשכולות חופפים, ולכן דירוג עדין עדיין זקוק לאות הלקסיקלי

# מה הפרויקט מראה



## צינור IR עברי מלא

קורפוס שנאסף עצמאית → עיבוד מקדים → 5 מאחזרים → הערכה קפדנית, ניתן לשחזור מלא.



## ההיברידי הוא ההמלצה

המודל היחיד שמנצח את שני קווי הבסיס בכל מדדי הדירוג.



## מדף ≠ ניצחון חינם

מקודד עברי מבוסס masked-LM הוא משלים שימושי, לא שדרוג מיידי לאחזור.



## המשך

מודל מכוון-אחזור (E5), למטיזציה עברית, וסט הערכה גדול ומדורג יותר.

# אתיקה ומגבלות



## נתונים ציבוריים ומורשים

כל-זכות (CC-BY-SA) + מידע ציבורי של ביטוח לאומי. ללא מידע אישי, ללא סריקת תוכן משתמשים.



## אינו ייעוץ משפטי

אב-טיפוס מחקרי. שימוש אמיתי חייב להציג קישורי מקור ולהפנות לרשות המוסמכת.



## הטיה וכיסוי

שישה תחומים בלבד; המורפולוגיה העברית פוגעת בלקסיקלי; ל-AlephBERT ייתכנו הטיות מקדם-אימון.



## סט הערכה קטן

40 שאלות, מתייג יחיד: מצביע על מגמה, אך אינו מובהק סטטיסטית.



# תודה

*אחזור סמנטי בעברית לשאלות על זכויות חברתיות*

יניק גוטיה · [github.com/YanikGotie/hebrew-rights-retrieval](https://github.com/YanikGotie/hebrew-rights-retrieval)



## גילוי נאות על שימוש ב-AI

נעשה שימוש בעוזר AI ככלי לכתיבת קוד (תבניות, תיעוד, ניפוי שגיאות). תכנון המחקר, הנתונים, סט ההערכה והמסקנות הם של המחבר; כל הקוד נבדק והובן.