

פרויקט גמר – עיבוד שפה טבעית

ד"ר איגור קליינר

המכון הטכנולוגי חולון (HIT)

1. מדיניות כללית

הפרויקט יתבצע בזוגות (חריגים דורשים אישור מיוחד מהמרצה).

הגבלות:

- חל איסור על שימוש ב-Kaggle (כולל דאטה-סטים, מחברות, תחרויות וקוד).
- שימוש בדאטה-סטים שחוקים מ-Tutorials (למשל IMDB בסיסי ללא חידוש) אינו מומלץ, אלא אם מוצגת זווית מחקרית מקורית וברורה.

מקוריות בבחירת הנתונים, שאלת המחקר ואסטרטגיית המידול תזכה להערכה חיובית.

2. מסלולי הפרויקט

על הסטודנטים לבחור באחד מהמסלולים הבאים:

מסלול 1 פרויקט לימודי מתקדם (Educational)

למידה עצמאית של שיטת NLP מתקדמת שלא נלמדה בכיתה.

- חובה:** הסבר תיאורטי ברור, תיאור מתמטי/אלגוריתמי, מימוש קוד, הדגמה אמפירית על נתונים אמיתיים, הערכה כמותית ודיון ביקורתי.
- אזהרה:** הצגה תיאורטית בלבד אינה מתקבלת. שקפים ללא ניסויים יקבלו ניקוד נמוך.

מסלול 2 שחזור מאמר מחקרי (Reproduction)

בחירה במאמר NLP שעבר ביקורת עמיתים (Peer-reviewed).

- חובה:** לשחזר לפחות ניסוי ליבה אחד, לממש רכיבי מפתח באופן עצמאי, ולהשוות תוצאות למאמר המקורי.

- **דרישה:** ניסיון לביצוע שיפור משמעותי (כגון: כיוון היפר-פרמטרים, ייצוג פיצ'רים חלופי, שימוש בדאטה-סט שונה, שינוי ארכיטקטורה, ניתוח שגיאות להפחתת טעויות).
- **אזהרה:** סיכום המאמר בלבד אינו מספיק. שחזור מדויק ללא ניסיון שיפור/וריאציה אינו מספק.

מסלול 3 פרויקט מונחה נתונים (Data-Driven)

נדרש Pipeline מלא של NLP.

- **חובה:** איסוף נתונים, עיבוד מקדים (Preprocessing), הנדסת פיצ'רים, לפחות שתי גישות מידול שונות, הערכה, אינטרפרטציה וניתוח שגיאות.
- **מומלץ:** עבודה בעברית, קורפוסים מדומיין ספציפי, איסוף עצמי של נתונים, מקורות שלא נחקרו רבות.

3. דרישות טכניות (חובה לכולם)

כל פרויקט חייב לכלול:

- מימוש בשפת Python.
- קישור ל-Google Colab או GitHub.
- הגשה במייל הכוללת ארכיון ZIP.
- קוד שניתן לשחזור (Reproducible) עם חלוקה ברורה ל-Train/Test.
- לפחות שתי מטריקות הערכה.
- ניתוח שגיאות: ניתוח של מינימום 10 דוגמאות שגיאה.
- לפחות 2 ויזואליזציות משמעותיות.

על הסטודנטים להיות מסוגלים להסביר כל חלק בקוד שלהם.

4. פורמט הגשה

פריטים נדרשים:

- **קישור:** Google Colab (רץ באופן מלא) או GitHub.
- **הגשה במייל:** קובץ ZIP המכיל את הדו"ח הסופי (PDF, עד 5 עמודים), מצגת, תיאור הדאטה-סט, ופרק גילוי נאות על שימוש ב-AI.

רשימת תיוג להגשה (חובה לכלול ב-ZIP):

- דו"ח (PDF) – עד 5 עמודים
- מצגת (PDF או PPTX)
- קוד (ייצוא מחברת Colab או תמונת מצב של המאגר)
- AI_USAGE.md – גילוי נאות מלא
- REFLECTION.md – רפלקציה אישית
- ETHICS.md – הצהרה אתית
- DATA.md – מקור הנתונים, רישיון וצעדי שחזור

אופן ההגשה: אימייל + קישור (Colab/GitHub). כתובת האימייל המדויקת ותאריכי היעד יפורסמו ב-Moodle.

הפרויקטים חייבים להיות ניתנים לשחזור מלא.

5. מדיניות שימוש ב-AI (גילוי נאות חובה)

ניתן להשתמש בכלי AI ככלי עזר בלבד. כל פרויקט חייב לכלול פרק בשם "גילוי נאות על שימוש ב-AI". גילוי נאות זה חייב להופיע בכל המקומות הבאים:

- **דו"ח:** פרק ייעודי
- **מחברת/Colab:** תא Markdown ראשון בכותרת "גילוי נאות על שימוש ב-AI"
- **מצגת:** שקף אחרון בכותרת "גילוי נאות על שימוש ב-AI"
- **מאגר/ZIP:** קובץ AI_USAGE.md

על הסטודנטים לפרט במפורש:

- באילו כלים נעשה שימוש.
- לאיזו מטרה ובאיזה היקף.
- מה נכתב מחדש או שונה ידנית.
- מה אומת באופן עצמאי.

פורמט נדרש: כלי / משימה / היקף / עריכה אנושית / אימות

שימוש מוסתר ב-AI מהווה עבירת משמעת אקדמית. הסטודנטים חייבים להבין ולהסביר את כל הקוד המוגש.

6. רפלקציה ובעלות טכנית (חובה)

כל דו"ח חייב לכלול פרק **רפלקציה אישית ובעלות טכנית** (מינימום עמוד מלא).

על הסטודנטים לתאר:

- מה כל אחד מימש באופן אישי.
- מה נכשל וכיצד תוקן.
- אתגרים טכניים שעלו.
- מה למדו ומה הפתיע אותם.
- מה היו משפרים בדיעבד.
- **יומן כישלונות:** 2-3 דברים קונקרטיים שנכשלו וכיצד תוקנו.
- **ראיות לבעלות:** מה כל חבר צוות עשה; יומן עבודה קצר.

לפרק זה משקל משמעותי בציון.

7. שיקולים אתיים (חובה)

כל פרויקט חייב לכלול **הצהרה על אתיקה ו-NLP אחראי** המתייחסת ל:

- שקיפות מקור הנתונים.
- שיקולי פרטיות.
- הטיות (Bias) בנתונים ומגבלות המודל.
- יישומים פוגעניים פוטנציאליים.
- רישוי נתונים/זכויות יוצרים ושימוש מותר.
- הסכמה/זמינות ציבורית (במיוחד לנתוני מדיה חברתית).

פרויקטים שיתעלמו מההיבטים האתיים יקבלו הערכה נמוכה יותר.

8. הגנה טכנית בעל פה

לאחר המצגת, כל צוות יעבור תשאול טכני של כ-5 דקות.

שאלות אפשריות:

- מדוע בחרתם במטריקה זו?
- מה יקרה אם נשנה את ההיפר-פרמטר X?
- מדוע המודל נכשל בדוגמה Y?
- מהן המגבלות של הגישה שלכם?

הביצועים בהגנה זו משפיעים על ציון הרפלקציה. מטרת ההגנה היא לוודא הבנה אותנטית ובעלות טכנית.

9. לוח זמנים

- **שבוע 4:** הצעת פרויקט (עד 2 עמודים). כולל בחירת מסלול, שאלת מחקר, נתונים, שיטות ואתגרים. נדרש אישור מרצה.
- **שבוע 5–6:** משוב ודיוק היקף הפרויקט.
- **שבוע אחרון של הסמסטר:** פרזנטציה (20–30 דקות, 20–40 שקפים). תאריכים מדויקים ב-Moodle.
- **הגשה סופית:** עד 4 שבועות לאחר המצגת. אין הגשות מאוחרות ללא אישור.
- **תאריכים קלנדריים:** מועדי הגשה מדויקים יפורסמו ב-Moodle.

10. מחוון הערכה (50% מציון הקורס)

המחוון מסכם ל-100% ומיושם על ציון הפרויקט (שהוא 50% מציון הקורס).

רכיב	משקל
איכות ההצעה	10%
מימוש טכני	20%
ריגורוזיות ניסויית	15%
שיפור / חדשנות	10%
מקוריות הנתונים	5%
דו"ח כתוב	10%
מצגת	10%
שקיפות AI	5%
רפלקציה + הגנה בע"פ	15%
סה"כ	100%

11. יושרה אקדמית

הדברים הבאים **אסורים בהחלט**:

- פרויקטים שנוצרו במלואם על ידי AI.
- סיוע AI ללא תיעוד.
- העתק-הדבק מ-Tutorials.
- שימוש ב-Pipelines של Kaggle או AutoML ללא הסבר מעמיק.
- שימוש במודלי טרנספורמר ללא ניתוח.

12. בונוס (עד +5%)

ייתכן עבור דאטה-סטים מקוריים במיוחד, תרומה ל-NLP בעברית, השוואה בין שיטות שונות, ניתוח מעמיק של תוצאות שליליות, או ניתוח שגיאות מתקדם.

הערה חשובה: הציון הסופי לא יעלה על 100%, גם במידה וייתנו בונוסים.